

딥러닝 기반 농작물 잎 이미지 병해충 진단 시스템

도메인 시프트(Domain Shift) 발견 및 극복 연구 보고

딥러닝분석 2조

목차

발표 구성 및 흐름 안내

1. 문제 정의

농업 병해충 진단의 필요성과 프로젝트 목표

2. 데이터셋 분석

Kaggle 데이터셋 구성 및 전처리 · 증강 전략

3. 모델 아키텍처 및 최적화

CNN → GAP 경량화 → EfficientNet-B0 도입

4. 실험실 모델 성과

EfficientNet-B0 검증 정확도 99.73% 달성

5. 도메인 시프트 발견

야외 환경 테스트 시 정확도 19.12%로 폭락

6. 가설 검증 및 결론

3가지 가설 실험을 통한 최적 해결책 도출

1. 문제 정의

농업 분야에서 딥러닝 기반 병해충 자동 진단의 필요성

현재의 문제 상황

- 전 세계 농작물의 약 **20~40%**가 매년 병해충으로 인해 손실
- 전문가 육안 진단에 의존 → **지리적·시간적 접근성** 한계 존재
- 비전문가(농민)가 초기 증상을 정확히 구분하기 어려워 **대응 시기 지연**

우리의 해결 목표

접근성 확보

스마트폰 촬영 이미지 1장으로 38종 병해충을 자동 분류하는 딥러닝 모델 구축

실시간 진단

GPU 가속 추론 환경을 활용하여 빠른 응답 시간 내에 높은 정확도의 진단 결과 제공

핵심 가치: 전문 인력 없이도 모바일 디바이스를 통해 누구나 즉시 병해충 종류를 식별하고 조기 대응할 수 있는 기술적 기반을 구축한다.

2-1. 데이터셋 개요

Kaggle New Plant Diseases Dataset (Augmented)



클래스 구성 예시

작물	포함 클래스	클래스 수
Apple	Apple Scab, Black Rot, Cedar Rust, Healthy	4
Tomato	Bacterial Spot, Early/Late Blight, Mosaic Virus, Healthy 등	10
Potato	Early Blight, Late Blight, Healthy	3
Grape	Black Rot, Esca, Leaf Blight, Healthy	4
Corn	Cercospora, Common Rust, Northern Leaf Blight, Healthy	4

* 총 10종 작물, 38개 클래스 (정상 + 질병 포함)

2-2. 데이터 전처리 및 증강

Albumentations 라이브러리
기반의 이미지 변환 파이프라인

공통 전처리

- Resize (224×224)**

CNN 입력 해상도 통일
- Normalize (ImageNet μ, σ)**

경사 하강법 수렴 속도 향상
- ToTensorV2**

PyTorch FloatTensor로 변환

학습 전용 증강

- Train Only**

RandomRotation ($\pm 30^\circ$)

촬영 각도 변화에 대한 기하학적 불변성 학습

HorizontalFlip (p=0.5)

좌우 비대칭 패턴을 균등하게 학습


ColorJitter

밝기·대비·채도·색조 변화로 조도 강건성 확보

3-1. 베이스라인 CNN 아키텍처

PlantDiseaseCNN — 4-Block Convolutional Neural Network

텐서 차원 흐름 (Feature Mapping)



각 블록 내부 구성

Conv Block 구성 흐름

```

Conv2d(3 × 3, padding=1)
→ BatchNorm2d
→ ReLU
→ MaxPool2d(2 × 2)
  
```

Classifier 구성 흐름

```

Flatten
→ Linear(50176, 512)
→ ReLU → Dropout(0.5)
→ Linear(512, 38)
  
```

채널 수를 **32→64→128→256**으로 점진적 확장하며 고수준 의미론적 특징을 추출하고, MaxPool로 공간 차원을 절반씩 축소하여 계산 효율성을 확보합니다.

3-2. 아키텍처 최적화: 5가지 모델 비교 분석

자체 CNN → GAP 경량화 → 전이학습 모델 (ResNet50, MobileNetV3, EfficientNet-B0) 비교

- Step 1. 전통적 CNN의 한계 발견 (Flatten 사용)**
Flatten 층으로 인해 파라미터가 약 **2,610만 개**로 폭발적 증가.
50층짜리 ResNet50(약 2,350만 개)보다 무거워 모바일/엣지 디바이스 배포에 부적합함을 발견.
- Step 2. 자체 경량화 달성 (GAP 도입) → 파라미터 98% 감소**
Flatten을 최신 논문 기법인 **GAP(Global Average Pooling)**로 직접 교체.
파라미터 2,610만 개 → **54만 개(0.5M)**로 98% 대폭 감소. 극강의 초경량 자체 모델 구축 성공.
- Step 3. 다양한 전이학습 모델 비교 실험**
자체 경량화 연구를 바탕으로 **ResNet50**(Residual Connection), **MobileNetV3**(Depthwise Conv), **EfficientNet-B0**(Compound Scaling) 3가지 SOTA 모델을 도입하여 성능과 효율을 비교 분석.

모델	분류기 구조	파라미터 수	평가
Baseline CNN	Flatten → Dense	26,099,494	가장 무거움
ResNet50	GAP + Residual Connection	23,585,894	깊은 층, 안정적 학습
MobileNetV3	GAP + Depthwise Conv	4,250,710	모바일 배포 최적화
EfficientNet-B0	GAP + Compound Scaling	4,056,226	최적 효율 + 99.73%
Baseline CNN (GAP)	GAP → Dense	540,454	극강 초경량 (98% ↓)

4. 학습 설정

하이퍼파라미터, 손실 함수 및 최적화 전략

항목	설정값	선택 이유
프레임워크	PyTorch 2.x + CUDA	GPU 가속 병렬 연산
손실 함수	CrossEntropyLoss	다중 분류 (38 클래스) 최적 손실 함수
옵티마이저	Adam	적응적 학습률, 안장점 돌파 능력
학습률 (LR)	0.001	Adam 기본 권장값, 안정적 수렴
배치 사이즈	32	GPU 메모리 대비 효율적 크기
에포크	10	베이스라인 성능 확인용 초기 실험

5. 실험실 모델 성과 (EfficientNet-B0)

PlantVillage
데이터셋 기
반 10 Epoch
학습 결과

BEST VAL LOSS

0.0094

BEST VAL
ACCURACY

99.73%

BEST
EPOCH

9

완벽한 실험실 AI 모델 구축 성공: EfficientNet-B0은 효율적인 파라미터(405만 개)로 38개 클래스를 거의 완벽하게 분류합니다. 단색 배경의 깨끗한 실험실 데이터에서는 사실상 최고 수준의 성능을 달성했습니다.

그런데... 이 모델이 실제 야외 환경에서도 통할까?

실험실의 단색 배경에서 **99.73%**를 달성한 이 모델을, 흙과 잡초가 뒤섞인 실제 야외 환경(PlantDoc 데이터)에 투입해 보았습니다...

6. 치명적 문제 발생: 도메인 시프트

실험실에서 야외
(In-the-wild)로
나갔을 때 벌어진
충격적인 결과



무엇이 문제인가?

- **실험실 데이터(PlantVillage):** 단색 배경에 잎사귀 하나만 깨끗하게 촬영된 이미지
- **야외 데이터(PlantDoc):** 흙, 잡초, 가지, 그림자 등 복잡한 배경이 뒤섞인 실제 환경 이미지
- 모델이 실험실의 **단색 배경 패턴에 완전히 과적합**되어, 야외 환경을 전혀 이해하지 못하는 전형적인 **도메인 시프트(Domain Shift)** 현상 발생

핵심 발견: 실험실에서 아무리 높은 정확도를 달성해도, 실제 현장 환경과의 괴리(Domain Gap)를 해결하지 못하면 실무 적용이 불가능하다는 사실을 확인했습니다.

7. 원인 분석: Grad-CAM 시각화

AI가 대체 어디를 보고 판단하는지, 모델의 시선을 직접 시각화

Grad-CAM이란?

Gradient-weighted Class Activation Mapping — 딥러닝 모델이 예측할 때 이미지의 어느 부위에 집중했는지를 히트맵으로 시각화하는 설명 가능한 AI(XAI) 기법입니다.



Grad-CAM 히트맵: 앞이 아닌 흙과 배경에 시선(붉은 색)이 쏠림

분석 결과

- **발견:** AI는 앞사귀의 병변을 전혀 보지 않고 있었습니다.
- **오류 원인:** 우측 사진처럼 뒷배경의 흙과 나

8-1. 가설 1: 물리적 전처리 도입

실패

배경이 문제라면, AI(rembg)로 배경을 물리적으로 제거하면 해결될까?

실험 설계

- **방법:** rembg(AI 배경 제거 모델)를 사용하여 야외 데이터 전체(학습 + 테스트)의 배경을 제거(누끼 따기)
- **기대:** 배경 노이즈가 사라지면 모델이 잎사귀에만 집중할 것



가설 1
(배경 제거)
학습 곡선:
47.8%
에서 수렴

결과 정확도

47.81%

실패 원인 분석

- 배경을 강제로 날리면 서 정답을 유추할 '**환경적 문맥(Context)**'까지 파괴됨
- 질병으로 싹어 들어간 **잎 끝부분(병변)**까지 배경으로 인식되어 함께 훼손됨

결론: 물리적 전처리(배경 제거)는 환경 문맥을 상실시키고 병변을 훼손하여, 오히려 모델의 판단 근거를 약화시킵니다.

8-2. 가설 2: 혼합 도메인 학습

실패

기존 실험실 데이터와 야외 데이터를 섞어서 학습하면 해결될까?

실험 설계

- **방법:** 실험실 데이터 5,000장 + 야외 데이터 2,500장을 혼합하여 파인튜닝
- **기대:** 과거의 깨끗한 데이터를 섞으면 질병 패턴 망각을 방지할 수 있을 것



가설 2
(데이터 혼합) 학습 곡선:
47.0%에서 한계

결과 정확도

47.01%

실패 원인 분석

- 모델이 가혹한 야외 환경에 빠르게 적응해야 할 시점에, **쉬운 데이터가 섞여 들어오면서 모델의 시선이 분산됨**
- 야외 환경 적응 (Adaptation)에 대한 **학습 집중도가 희석되어 안일해짐**

결론: 쉬운 데이터를 혼합하면 야외 환경 적응에 대한 모델의 시선이 분산되어, 도메인 적응에 오히려 역효과를 초래합니다.

8-3. 가 설 3: 본 질적 도메 인 적응

성공

원본 야외 데이터
만 투입 + 가혹한
증강 + 최신 수학적
최적화로 전이학습

실험 설계

타겟 도메 인 집중

야외 데이터
(PlantDoc)
원본만을 집
중 투입하여
전이학습 수
행

가혹한 데이터 증강

ColorJitter(빛 번짐),
RandomResizedCrop(랜
덤 크롭) 등 극한 증강 적용

수학적 최 적화

Cosine
Annealing
LR 스케줄러
+ Label
Smoothing
기법 도입

기존 야외 정확도

19.1%



최종 정확도

60.6%



가설 3
학습 곡
선:

60.56%
까지 지
속 상승

3배 이상 향상! (배경 제거, 데이터 혼합)를 버리고
강건성 최적화에 집중한 방법이 가장 효과적임을
입증했습니다.

9. 결론: 가설 검증 종합 비교

3가지 가설의 실험 결과를
정량적으로 비교 분석

가설	전략	정확도	결과
기존 (도메인 시프트)	실험실 가중치 그대로 야외 테스트	19.12%	실패
가설 1 (물리적 전처리)	rembg 로 배경 제거 후 파인튜닝	47.81%	실패
가설 2 (혼합도메인)	실험실 +야외 데이터 섞어서 학습	47.01%	실패
가설 3 (본질적 적응)	가혹한 증강 + 수학적 최적화 전이학습	60.56%	최선

핵심 교훈 및 성과: 방대한 실험실 데이터로 학습된 기존 지식(가중치)을 적극 활용한 전이학습 덕분에, 단 2,589장의 매우 적은 야외 데이터만으로도 짧은 시간 안에 60.56%

10. 향후 연구 방향

도메인 적응 성능(80~90% 이상)을 목표로 한 고도화 전략

Vision Transformer (ViT) 도입

국소적 픽셀에 집착하는 CNN의 한계를 넘어, 글로벌 문맥에 Self-Attention 하여 배경 노이즈를 무시하고 잎사귀 병변에만 집중하도록 유도

적대적 도메인 적응 (DANN)

모델 내부에 기울기 반전 계층 (Gradient Reversal Layer)을 추가 하여, 실험실과 야외의 도메인 차이를 모델이 구별하지 못하도록 강제

객체 탐지 (YOLO) 파이프라인 결합

무식한 배경 제거 대신, 전체 사진에서 '식물의 잎사귀' 영역만 Bounding Box로 정확히 크롭한 뒤 분류를 수행하여 노이즈 차단

자기 지도 학습 (Self-Supervised)

정답 없는 수백만 장의 야외 식물 사진으로 Pre-training을 진행하여 야외 도메인 지식을 사전에 학습시킨 뒤 파인튜닝

방향성: 현재 V2 모델(60.56%)의 아키텍처를 기반으로, 위 전략들을 단계적으로 적용하여 야외 환경에서의 정확도를 80~90% 이상으로 끌어올리는 것을 목표로 후속 연구를 진행할 계획입니다.

감사합니다

질의응답 (Q&A)

딥러닝 기반 농작물 잎 이미지 병해충 진단 시스템

도메인 시프트 극복 연구 보고

